

Nâng cao độ chính xác dự đoán quỹ đạo bão bằng mô hình Transformer

Nguyễn Văn Thành, Nguyễn Đăng Huỳnh, Nguyễn Ngọc Tân, Nguyễn Thái Minh, Nguyễn Nam Hoàng

Trường Đại học Công Nghệ - Đại học Quốc Gia Hà Nội
felicenguyen2001@gmail.com, nguyendanghuynh1804@gmail.com,
tan.nguyen@vnu.edu.vn, minhnt@hnm.edu.vn, hoangnn@vnu.edu.vn

Tóm tắt nội dung—Bão là một loại hình thời tiết cực đoan. Do đó, công tác dự báo quỹ đạo bão là vô cùng quan trọng trong việc bảo vệ tính mạng và tài sản của người dân. Tuy nhiên, việc dự báo bão là cực kỳ khó khăn, bởi vì quỹ đạo của bão thường xuyên thay đổi. Trong nghiên cứu này, chúng tôi đề xuất một phương pháp học sâu là mạng Transformer cải tiến để dự đoán quỹ đạo chuyển động của bão trong 6 giờ tiếp theo. Dữ liệu về các cơn bão dùng để huấn luyện mô hình được lấy từ trung tâm khí tượng quốc gia Hoa Kỳ (National Oceanic and Atmospheric Administration - NOAA) [1]. Các kết quả mô phỏng cho thấy độ chính xác của phương pháp đề xuất cao hơn các phương pháp truyền thống. Ngoài ra, phương pháp đề xuất còn cho kết quả nhanh và ít tốn chi phí.

Keywords—Dự đoán đường đi, bão nhiệt đới, học sâu, mô hình transformer.

I. MỞ ĐẦU

Bão nhiệt đới hay xoáy thuận nhiệt đới (Tropical Cyclone) được coi là các hiện tượng thời tiết cực đoan. Những cơn bão lớn (sức gió từ 63 km/h trở lên) có thể gây thiệt hại lớn về tính mạng và tài sản cho người dân ở các khu vực ven biển trên toàn thế giới [2]. Mỗi năm, trên toàn thế giới có khoảng 40 đến 50 cơn áp thấp nhiệt đới (hình thành xung quanh đường xích đạo) đã phát triển thành bão. Các biện pháp dự báo quỹ đạo bão một cách chính xác và kịp thời sẽ giúp các cơ quan có thẩm quyền có những biện pháp đối phó và phòng tránh, giúp giảm thiểu tối đa thiệt hại do bão gây ra. Tuy nhiên, với sự phức tạp trong việc di chuyển của bão cũng như sự biến đổi khí hậu toàn cầu, việc dự báo đường đi của bão gặp rất nhiều khó khăn.

Sự phát triển của công nghệ dự báo quỹ đạo bão đã có những tiến bộ rất đáng ghi nhận trong những năm qua. Tuy nhiên, hầu hết của các phương pháp dự báo quỹ đạo hiện nay về bản chất là thống kê [3]. Cụ thể, Trung tâm dự báo bão quốc gia Hoa Kỳ (NOAA) hiện đang sử dụng một số phương pháp dự báo như i) hệ thống dự báo toàn cầu (Global Forecast System - GFS) [4] và mô hình nghiên cứu và dự báo thời tiết bão (Hurricane

Weather Research and Forecasting- HWRF); ii) hệ thống quan sát bằng vệ tinh GOES (Geostationary Operational Environmental Satellite) [5]; và iii) hệ thống sử dụng mạng lưới cảm biến thời tiết trên biển và đất liền. Đầu tiên, hệ thống GFS và mô hình HWRF tính toán và dự báo chuyển động của bão bằng cách sử dụng các thuật toán và phương trình dựa trên dữ liệu quan sát và thông tin về điều kiện thời tiết hiện tại. Tuy nhiên, GFS phụ thuộc vào chất lượng và sự chính xác của dữ liệu đầu vào như cường độ gió, áp suất và thông tin thời tiết hiện tại. Điều này có thể gặp khó khăn trong việc dự báo các yếu tố không xác định hoặc khó lường như sự phát triển nhanh chóng và biến đổi của bão. Hệ thống thứ hai sử dụng vệ tinh GOES để thu thập dữ liệu liên tục về quỹ đạo và cường độ của bão. Thông qua việc theo dõi sự thay đổi của bão trong thời gian thực, NOAA có thể cung cấp thông tin cập nhật và dự báo cho người dùng. Tuy nhiên việc này phụ thuộc vào khả năng thu thập và truyền dữ liệu từ vệ tinh, có thể bị ảnh hưởng bởi điều kiện thời tiết xấu hoặc sự cố kỹ thuật. Khả năng quan sát hạn chế trong một số vùng biển xa đảo hoặc khu vực mà không có vệ tinh phủ sóng cũng là một vấn đề cần giải quyết. Cuối cùng, NOAA sử dụng một mạng lưới các cảm biến thời tiết để thu thập dữ liệu về các yếu tố như áp suất, gió, nhiệt độ và độ ẩm. Phương pháp này đòi hỏi sự triển khai và duy trì một hệ thống phức tạp của các cảm biến và thiết bị thu thập dữ liệu trên một diện tích rộng và có thể gặp khó khăn trong việc thu thập dữ liệu trong các vùng biển xa đảo hoặc khu vực xa xôi và hẻo lánh. Các phương pháp trên bị hạn chế do tính phức tạp và phi tuyến của các hệ thống khí quyển và sai số trong việc tính toán những phương trình phức tạp.

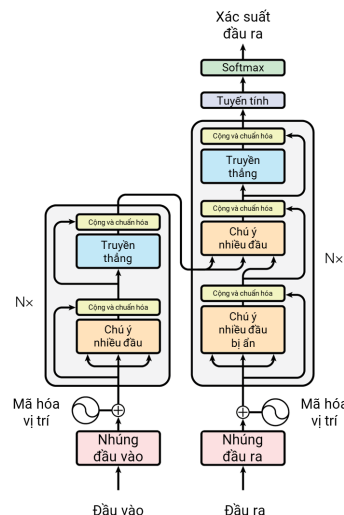
Gần đây, xuất hiện một vài phương pháp dự báo bão dựa trên học sâu, như mô hình Mạng hồi quy (Recurrent Neural Network - RNN), Bộ nhớ dài-ngắn hạn (Long Short-Term Memory - LSTM) [6] và Nút Hồi tiếp có Cổng (Gated Recurrent Unit - GRU), có khả năng lưu trữ thông tin trạng thái

trước đó và sử dụng nó để dự đoán quỹ đạo tiếp theo; mạng nơ-ron tích chập (Convolution Neural Network - CNN) có khả năng nhận biết và học các đặc trưng không gian trong dữ liệu và có thể áp dụng để dự đoán quỹ đạo bão dựa trên các đặc trưng không gian của quỹ đạo đó [7]. Tuy nhiên, các phương pháp kể trên còn tồn tại một vài hạn chế như gặp khó khăn khi xử lý các quỹ đạo bão trong thời gian dài, mô hình chỉ có thể xem xét các đặc trưng không gian tại mỗi thời điểm cụ thể, mà không cung cấp thông tin về sự tương tác không gian giữa các điểm dữ liệu trong quỹ đạo. Đặc biệt là khi quỹ đạo bão có kích thước lớn hoặc cần xử lý nhiều đặc trưng và thông tin từ nguồn dữ liệu khác nhau, các phương pháp học sâu truyền thống như RNN, GRU hay CNN có thể gặp khó khăn trong việc mở rộng để xử lý các tác vụ phức tạp và dữ liệu lớn [9]. Mô hình Transformer với khả năng học được mối quan hệ phi tuyến giữa các yếu tố khí tượng như độ ẩm, áp suất, vị trí, v.v. và khả năng xử lý chuỗi có độ dài khác nhau có thể mang lại tiềm năng to lớn trong việc nâng cao độ chính xác dự đoán quỹ đạo của bão. Do đó, trong bài báo này, chúng tôi đề xuất sử dụng mô hình Transformer nhằm khắc phục những điểm hạn chế của các phương pháp trên.

Cấu trúc của bài báo được trình bày như sau. Kiến trúc và luồng hoạt động của mô hình Transformer gốc và do chúng tôi đề xuất được trình bày lần lượt trong phần II và III. Cuối cùng, chúng tôi so sánh kết quả dự đoán quỹ đạo bão bằng việc sử dụng mô hình Transformer đề xuất với các mô hình học sâu khác như LSTM, và các phương pháp đang được sử dụng bởi trung tâm khí tượng quốc gia Hoa Kỳ trong phần IV.

II. MÔ HÌNH TRANSFORMER

Mô hình Transformer là một kiến trúc mạng nơ-ron dùng để xử lý dữ liệu chuỗi được giới thiệu bởi Vaswani vào năm 2017 [10]. Mô hình Transformer sử dụng cơ chế Chú ý nhiều đầu (Multi-Head Attention) và Mạng truyền thẳng (Feed Forward Network) cho thấy hiệu quả cao trong nhiều tác vụ xử lý ngôn ngữ tự nhiên. Vì vậy, trong nghiên cứu này, mô hình Transformer được áp dụng để dự báo quỹ đạo của bão nhiệt đới nhằm tận dụng các ưu điểm của nó như khả năng học các mối quan hệ phi tuyến giữa các yếu tố khí tượng như độ ẩm, áp suất, nhiệt độ, tốc độ gió, v.v. thông qua lớp Chú ý. Điều này có thể giúp mô hình học được mối tương quan giữa các biến thời tiết khác nhau và dự báo




Hình 1: Kiến trúc Transformer được đề xuất bởi Vaswani [10].

quỹ đạo của bão nhiệt đới chính xác hơn. Ngoài ra, mô hình Transformer còn có sự linh hoạt trong việc lựa chọn kích thước của mô hình để phù hợp với độ phức tạp của dữ liệu đầu vào và các yêu cầu tính toán. Theo Hình 1, kiến trúc của mô hình Transformer gồm có hai phần chính là Bộ mã hóa (Encoder) và Bộ giải mã (Decoder). Trong đó, bộ mã hóa (giải mã) gồm nhiều vòng mã hóa (giải mã), mỗi vòng bao gồm lớp Chú ý và Truyền thẳng. Bộ mã hóa được sử dụng để trích xuất các đặc trưng từ dữ liệu đầu vào và bộ giải mã sử dụng các đặc trưng này để đưa ra kết quả [11].


Một số nghiên cứu gần đây cũng đã áp dụng mô hình Transformer cải tiến để dự báo hạn hán [12] và để bám vết và dự báo cường độ của bão nhiệt đới [13]. Trong bài báo [12], các tác giả đề xuất mô hình Transformer sâu có bốn lớp mã hóa và giải mã với kết quả cho thấy việc sử dụng Transformer mang lại sự dự đoán dài hạn tốt hơn mô hình LSTM truyền thống. Bài báo [13] là kết quả nghiên cứu mới nhất (tháng 7 năm 2023) trong đó đề xuất mạng Transformer cho đồng thời bám vết bão và dự đoán cường độ bão. Trong bài báo này, các tác giả sử dụng dữ liệu về bão ở Trung Quốc để thử nghiệm và cho kết quả tốt hơn mô hình RNN.

III. MÔ HÌNH TRANSFORMER ĐỀ XUẤT KẾT HỢP LƯỚI TOA ĐỘ

Từ phân tích kiến trúc của mô hình trên, trong phần này, chúng tôi đề xuất sử dụng mô hình



Hình 2: Các điểm xuất hiện của bão từ 1944 – 2022.



Hình 3: Lưới tọa độ với độ phân giải 01 kinh độ \times 01 vĩ độ.

Transformer, kết hợp với lưới tọa độ nhằm nâng cao độ chính xác và giảm độ phức tạp của phương pháp như được trình bày dưới đây.

A. Mô hình lưới

Hình 2 cho thấy các điểm kinh độ và vĩ độ của các cơn bão được ghi lại bởi Dữ liệu thời tiết Unisys được sử dụng để đào tạo và kiểm tra mô hình [14]. Con số này cho phép chúng ta thấy chuyển động thông thường của các quỹ đạo bão được cung cấp thông tin khí quyển nhất định. Một lưới tinh chỉnh được đặt trên các điểm kinh độ và vĩ độ để giảm các lỗi cắt ngắn, trong khi đó cho phép mô hình tỷ lệ lớn hơn, gói gọn các đối tượng quy mô nhỏ chính xác hơn. Đây là một sự sắp xếp lý tưởng cho các Transformer để nắm bắt một cách tối ưu sự phức tạp của quỹ đạo bão. Trong bài báo này, chúng tôi đề xuất huấn luyện mô hình Transformer kết hợp với mô hình lưới trong nghiên cứu [15]. Cụ thể là, Transformer sẽ học chuyển động của một quỹ đạo bão di chuyển từ vị trí lưới này sang vị trí lưới khác. Mô hình lưới trong hình 3 có tất cả 23,533 điểm nhận dạng lưới.

B. Dữ liệu

Chúng tôi sử dụng dữ liệu được lấy từ trung tâm dự báo bão NOAA (Cơ quan quản lý khí quyển và đại dương quốc gia Hoa Kỳ) [1]. Dữ liệu chứa thông tin của các cơn bão xuất hiện từ năm 1852 cho tới năm 2022 của biên Đại Tây Dương, bao gồm các thông tin như: vị trí của tâm bão mỗi 6 giờ (vĩ độ và kinh độ), tốc độ gió (tính theo hải lý) và áp suất trung tâm tối thiểu. Sau khi loại bỏ đi các năm chứa nhiều dữ liệu bị lỗi, tập dữ liệu chứa các cơn bão từ 1944 đến 2022, có tổng cộng 982 cơn bão xuất hiện, với tổng 22,545 dòng dữ liệu (các dữ liệu cách nhau 6 giờ).

Với dữ liệu về kinh độ và vĩ độ của cơn bão, các đặc tính về khoảng cách và hướng đi của cơn bão được tính toán để giúp mô hình có thể dự đoán quỹ đạo của bão tốt hơn. Cụ thể, khoảng cách (đơn vị là dặm) giữa vị trí hiện tại của cơn bão và vị trí dự đoán trong 6 giờ tiếp theo được tính toán bằng việc sử dụng thư viện Geopy. Đây là một thư viện cho phép ta tính toán khoảng cách giữa 2 điểm khi biết kinh độ và vĩ độ của các điểm đó. Tương tự, hướng đi của cơn bão được xác định bởi góc β giữa hai vị trí liên tiếp của cơn bão [16]:

$$\angle\beta = \arctan\left(\frac{\sin(\Delta\lambda)\cos(\phi_2)}{\cos(\phi_1)\sin(\phi_2) - \sin(\phi_1)\cos(\phi_2)\cos(\Delta\lambda)}\right), \quad (1)$$

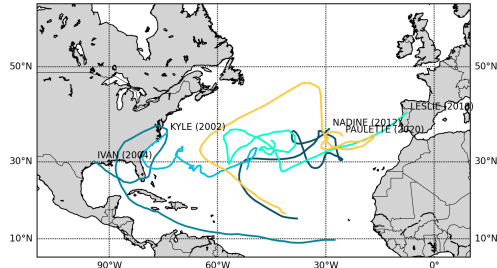
trong đó, $\angle\beta \in [0, 360]$, nếu β có giá trị âm, nó sẽ được cộng thêm với 360 để chuyển đổi thành giá trị dương. (λ_1, ϕ_1) và (λ_2, ϕ_2) lần lượt là các tọa độ (kinh độ, vĩ độ) của cơn bão tại vị trí hiện tại và vị trí dự đoán trong 6 giờ tiếp theo. Ngoài ra, $\Delta\lambda = \lambda_2 - \lambda_1$. Tiếp theo, ta sẽ tính điểm nhận dạng (gridID) của bão trên lưới tọa độ tương ứng với vị trí bão theo kinh độ và vĩ độ như sau:

$$gridID = \lfloor \lambda - \lambda_{min} \rfloor \Phi + \lfloor \phi - \phi_{min} \rfloor, \quad (2)$$


trong đó, $\lfloor x \rfloor$ là hàm làm tròn xuống của x , $\lfloor x \rfloor$ là hàm làm tròn lấy phần nguyên gần nhất của x , $\Phi = \phi_{max} - \phi_{min}$.

C. Xử lý dữ liệu

Mô hình Transformer nhận vào một dữ liệu dạng chuỗi, nhưng mỗi cơn bão có thời hạn diễn ra ngắn dài khác nhau, nên số 0 được đệm thêm vào đuôi để các chuỗi có cùng độ dài. Do cơn bão có chuỗi thời gian diễn ra dài nhất có kích thước là 96, chúng tôi đệm thêm sao cho tất cả các cơn bão có độ dài là 100. Khi đó, tập dữ liệu huấn luyện có 98,200 mẫu với 5 đặc tính lần lượt là tốc độ gió, áp suất, khoảng cách, hướng di chuyển, và điểm nhận dạng



Hình 4: Quỹ đạo của 5 cơn bão dài nhất.




Hình 5: Cấu trúc mô hình Transformer được đề xuất.

lưới. Tiếp theo, dữ liệu được phân khúc, với mỗi khúc có 13 phần tử và 12 phần tử đầu sẽ được sử dụng làm đầu vào và nhận dạng lưới của phần tử cuối làm nhãn dự đoán. Cuối cùng, dữ liệu được phân chia làm tập huấn luyện và tập kiểm thử với tỷ lệ là 85/15 để có thể đánh giá mô hình.

D. Mô hình Transformer đề xuất

Hình 5 mô tả mô hình Transformer được đề xuất trong bài báo này. Sau khi dữ liệu đã được biến đổi thành dạng chuỗi, với mỗi chuỗi có độ dài là 12 và mỗi phần tử là một vector 5 chiều. Với phần tử của một chuỗi, lớp Chú ý cho phép nó quan sát được các vị trí khác trong chuỗi để có thể mã hóa lại phần tử hiện tại tốt hơn, tập trung vào những phần quan trọng. Đặc biệt, lớp này còn được làm mịn bằng cách sử dụng nhiều đầu kết hợp với nhau. Điều này giúp các phần tử trong chuỗi có thể mở rộng khả




Hình 6: Biểu đồ thể hiện hàm mất mát của tập huấn luyện và tập kiểm thử sau mỗi lần chạy

năng tập trung đến nhiều vị trí khác nhau. Sau đó, các phần tử này được đưa đến qua lớp Truyền thẳng với hàm kích hoạt GELU (Gaussian Error Linear Unit) [17] để biến đổi các vector biểu diễn, giúp cho lớp tiếp theo dễ dàng tiếp nhận hơn.

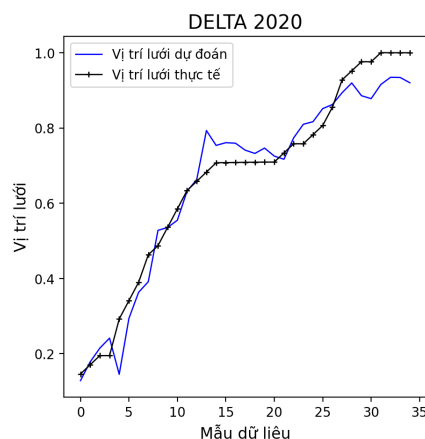
Dữ liệu sẽ được đưa qua 3 lớp mã hóa để có được các vector biểu diễn tốt hơn. Cuối cùng, các vector này sẽ được đưa qua lớp Mạng nơ-ron nhiều lớp (Multi-layer Perceptron - MLP) đầu ra, với hai lớp con lần lượt gồm 12 và 1 nơ-ron, cùng hàm kích hoạt cho mỗi lớp là ReLU (Rectified Linear Unit) và \tanh . Nơ-ron ở lớp cuối cùng thể hiện cho nhận dạng lưới dự đoán. Mô hình sử dụng hàm hyperbol tanh cho hàm kích hoạt cuối cùng thay vì các hàm phổ biến khác như ReLU hay Sigmoid. Điều này do chức năng của hàm này cho phép mô hình xuất ra các giá trị trong khoảng $[-1, 1]$ để mô hình có thể chuyển động theo mọi hướng tốt hơn [15]. Hình 6 và 7 lần lượt thể hiện lỗi mất mát và độ chính xác của mô hình sau mỗi lần huấn luyện.

IV. KẾT QUẢ VÀ ĐÁNH GIÁ


Mô hình Transformer đề xuất được huấn luyện trên GPU Testa T4 của Google Colab trong khoảng thời gian 6 phút với 100 lần để tìm mất mát nhỏ nhất. Mô hình được thực thi với hàm mất mát Sai số bình phương trung bình (Mean square error - MSE), tối ưu Adam và thang đánh giá độ chính xác. Sau quá trình huấn luyện, mô hình cho ra được lỗi mất mát MSE trên tập kiểm thử là 0.0086 và với độ chính xác là 0.78 (Bảng I). Hình 8 và Hình 9 cho thấy ví dụ của 2 cơn bão lần lượt là Ivan (năm 2004) và Delta (năm 2020) mà mô hình Transformer được đề xuất có thể dự báo thành công quỹ đạo bão trong



Hình 7: Biểu đồ thể hiện độ chính xác của tập huấn luyện và tập kiểm thử sau mỗi lần chạy



Hình 9: Dự đoán quỹ đạo của cơn bão DELTA (2020).



Hình 8: Dự đoán quỹ đạo của cơn bão IVAN (2004).

khoảng thời gian 6 giờ. Biểu đồ cho thấy các vị trí lưới được dự đoán gần sát với quỹ đạo đường đi của bão trong thực tế.


Các biện pháp đo lường hiệu suất của Trung tâm bão quốc gia (National Hurricane Center - NHC) được báo cáo như một phần của Đạo luật Kết quả và Hiệu suất của Chính phủ (Government Performance and Results Act - GPRA) năm 1993 được trình bày ở đây [14]. Các biện pháp hiện tại của NHC là thống kê các lỗi theo dõi và cường độ trung bình

hàng năm của lưu vực Đại Tây Dương trong 48 giờ đối với tất cả các cơn bão nhiệt đới. Mặc dù, NHC đưa ra dự báo cho các khoảng thời gian kéo dài từ 12 đến 120 giờ, dự báo 48 giờ thường rất quan trọng đối với các nhà quản lý khẩn cấp và các hành động chuẩn bị. Do sự biến động tự nhiên trong các đặc điểm theo dõi của cơn bão nhiệt đới, sai số hàng năm có thể thay đổi đáng kể từ năm này sang năm khác.

Hình 10 cho thấy cả hai phương pháp dự báo bão sử dụng mô hình Transformer đề xuất và của NOAA đều hoạt động tốt hơn so với yêu cầu của GPRA. Ngoài ra, mô hình Transformer đề xuất sử dụng lưới tọa độ hoạt động tốt hơn các phương pháp NHC hiện đang sử dụng. Hơn nữa, các mô hình động thống kê được sử dụng bởi NHC thường mất nhiều giờ để đưa ra một dự đoán duy nhất bằng cách sử dụng các siêu máy tính tiên tiến nhất thế giới. Trong khi đó, việc sử dụng các mô hình học sâu như mô hình Transformer đề xuất có thể trả về các dự báo chính xác và nhanh hơn đáng kể. Tuy nhiên, có thể thấy rằng việc sử dụng mô hình Transformer đề xuất cho việc dự báo đường đi của bão còn gặp nhiều thách thức, ví dụ như mô hình có thể bị overfitting nếu không được kiểm soát kỹ càng hoặc dữ liệu không cân bằng. Điều này có thể dẫn đến sự thất bại của mô hình trong việc dự báo quỹ đạo bão. Mô hình Transformer có cấu trúc phức tạp và yêu cầu tính toán khá cao, đặc biệt khi huấn luyện trên một lượng lớn dữ liệu. Điều này có thể gây khó khăn trong việc triển khai mô hình trên các thiết bị có tài nguyên hạn chế.

Bảng I: So sánh độ chính xác giữa mô hình LSTM [6] và mô hình Transformer đề xuất

	MSE	Độ chính xác
Mô hình LSTM	0.0160	0.685
Mô hình Transformer đề xuất	0.0086	0.783



Hình 10: Biểu đồ so sánh dự đoán lỗi của NHC vs. mô hình Transformer vs. GPRA 48h dự đoán (hải lý).

V. KẾT LUẬN

Trong nghiên cứu trên, chúng tôi đã triển khai phương pháp dự báo quỹ đạo bão trong 6 giờ liên tục bằng mô hình Transformer kết hợp với bản đồ dạng lưới. Mô hình dự đoán thành công quỹ đạo của bão trong khoảng thời gian 6 giờ tiếp theo, với độ chính xác là 0.783 và MSE là 0.0086. Khi so sánh với các phương pháp của NOAA và Đạo luật GPRA, mô hình cho thấy hiệu suất tốt hơn cũng như hoàn thành quá trình đào tạo nhanh.

TÀI LIỆU

- [1] "National Hurricane Center," National Oceanic and Atmospheric Administration, [Online]. Available: <https://www.nhc.noaa.gov/data/#hurdat>.
- [2] R. Chen, W. Zhang, and X. Wang, "Machine Learning in Tropical Cyclone Forecast Modeling: A Review," *Atmosphere*, vol. 11, no. 7, 2020.
- [3] H. Wang et al., "A Statistical Forecast Model for Atlantic Seasonal Hurricane Activity Based on the NCEP Dynamical Seasonal Forecast", *J. Climate*, vol. 22, no. 17, pp. 4481–4500, 2009.
- [4] NOAA, "NOAA Global Forecast System (GFS)," [Online]. Available: <https://registry.opendata.aws/noaa-gfs-bdp-pds/>.
- [5] NASA, "GOES Satellite Network," [Online]. Available: <https://www.nasa.gov/content/goes>.
- [6] S. Alemany et al., "Predicting Hurricane Trajectories using a Recurrent Neural Network," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 33, no.01, pp. 468–475, 2018.
- [7] T. Kim et al, "Near real-time hurricane rainfall forecasting using convolutional neural network models with Integrated Multi-satellite Retrievals for GPM (IMERG) product," *Atmospheric Research*, vol. 270, 2022.
- [8] R. Cahuantzi et al, "A comparison of LSTM and GRU networks for learning symbolic sequences," arXiv:2107.02248, 2021
- [9] R. Bose et al, "A real time prediction methodology for hurricane evolution using LSTM recurrent neural networks," *Neural Comput & Applic 34* 17491–17505 (2022)
- [10] A. Vaswani et al., "Attention Is All You Need," *Adv. Neural Inf. Process. Syst.*, 2017.
- [11] "Transformer's Encoder-Decoder", [Online]. Available: <https://kikaben.com/transformers-encoder-decoder/>
- [12] A. C. Amanambu et al., "Hydrological Drought Forecasting Using a Deep Transformer Model", *MDPI Water*, Vol. 14, Issue 22
- [13] W. Jiang et al., "Transformer-based tropical cyclone track and intensity forecasting", *Journal of Wind Engineering and Industrial Aerodynamics*, Vol. 238, July 2023
- [14] NOAA, "National Hurricane Center Forecast Verification," [Online]. Available: <https://www.nhc.noaa.gov/verification/verify8.shtml>.
- [15] G. E. Birchfield, "Numerical Prediction of Hurricane Movement with the Use of a Fine Grid," *J. Atmos. Scien.*, vol. 17, no. 4, pp. 406 - 414, 1960.
- [16] "Formula to Find Bearing or Heading angle between two points: Latitude Longitude," [Online]. Available: <https://www.igismap.com/formula-to-find-bearing-or-heading-angle-between-two-points-latitude-longitude/>.
- [17] D. Hendrycks et al, "Gaussian Error Linear Units (GELUs)," *arXiv preprint arXiv:1606.08415*, 2016.